

Master Informatique spécialité Intelligence Artificielle

Approches centrées sur les données

5 septembre 2024

Introduction à la modélisation



L'apprentissage machine a deux buts principaux

- Prédire l'avenir: étant donnée un état (une donnée), quelle est la "sortie" d'un processus?
- Extraire une information simple à partir de données complexes: étant donnée une image, identifier l'objet présent

Introduction à la modélisation



Comment fonctionne une intelligence artificielle?

- La donnée d'entrée (l'état du monde) est numérisée: $(x_1, x_2, x_3, \dots, x_n)$
- Une fonction mathématique, $\mathcal{F}$, est appliquée à cette entrée pour produire la sortie souhaitée.

$$\mathcal{F}(x_1, x_2, x_3, \dots, x_n) = \hat{y} \quad (1)$$

La fonction mathématique est appelée un **modèle**.



Comment obtenir un modèle?

L'estimer" directement ou le trouver par déduction (humaine)

Le champ de pesanteur est le champ attractif qui s'exerce sur tout corps doté d'une masse sur la Terre (ou un autre astre). Il s'agit d'un champ d'accélération, souvent appelé plus simplement pesanteur ou « g » et valant $9,80665 m.s^{-2}$. L'essentiel de la pesanteur terrestre est due à la gravité, mais s'en distingue du fait de l'accélération axifuge induite par la rotation de la Terre sur elle-même.

Deuxième loi de Newton prédisant l'accélération d'un corps

Le poids d'un objet est donné par: $P = m \times g$

La **donnée d'entrée**: la masse, détermine la **sortie**: force qui s'exerce sur Terre (constante gravitationnelle).

La valeur du paramètre g a été déterminée expérimentalement.

Comment obtenir un modèle?



Pour des problèmes complexes: l'apprentissage automatique

- Apprendre à partir d'exemple la "loi" qui régit un phénomène
- Fonctionne même si le nombre de paramètres est très grands (plusieurs milliards)
- Utilise des méthodes d'optimisation (minimisation, maximisation de fonction mathématique)



Comment obtenir un modèle?



Si $\mathcal{F}$ est une droite (modèle linéaire) alors $\mathcal{F}$ est de la forme:

$$\mathcal{F}(x) = a \times x + b \quad (2)$$

où a et b sont les paramètres du modèle. Selon les valeurs de a et b on obtiendra des modèles plus ou moins proches de la réalité observée.



Comment obtenir un modèle?



Méthode et objets de ce cours

- Déterminer la forme du modèle (type de fonction mathématique)
- Trouver les bons paramètres, c-à-d le bon modèle
- Être capable de déterminer/vérifier si le modèle est "bon" ou pas




Fonction de coût et notions de risque

Contexte



- Exemple: classification binaire
- Chaque point d'un carré appartient à une zone "jaune" ou "verte"
- La structure de ces zones est inconnue
- Le carré contient une infinité de points: impossible de mesurer pour tous



Définition



Fonction de coût

On définit une fonction de coût l de $[0, 1] \times [0, 1] \times \mathbb{R} \rightarrow \mathbb{R}_+$. Cette fonction de coût sert à mesurer l'erreur commise par le système automatique.

Définition



Risque réel

Le **risque réel** est l'espérance de la fonction de coût sur la **distribution de données** $\mathcal{D}$ comme décrit par l'équation suivante.

$$L \underbrace{\mathcal{D}}_{\text{Data distribution}} \underbrace{(h)}_{\text{Predictor}} = \underbrace{\mathbb{E}_{(x,y) \sim \mathcal{D}}}_{\text{Expectation}} \underbrace{[l((x_1, x_2, y), h)]}_{\text{Loss}} \quad (3)$$

où (x_1, x_2) sont les données d'entrée, y la classe du point correspondant et h le classifieur (modèle) utilisé pour prédire la classe.

Distribution inconnue: impossible à calculer.

Définition



Risque empirique

Étant donné un jeu fini de données, $S = (x_1^i, x_2^i)\}_{i \in [1, m]}$ le **risque empirique** calculé sur ce jeu de données est la moyenne de la fonction de coût **sur ce jeu de données** comme indiqué par l'équation suivante.

$$\underbrace{L}_\text{Dataset} \underbrace{S}_\text{Dataset} \underbrace{(h)}_\text{Predictor} = \underbrace{\frac{1}{m} \sum_{i=1}^m}_{\text{Average}} \underbrace{[l((x_1^i, x_2^i, y_i), h)]}_\text{Loss} \quad (4)$$

Le risque réel est une somme finie: nous pouvons mesurer les valeurs pour les points considérés et calculer ce risque.

Définition



Objectif de l'apprentissage automatique


- Le risque réel est la limite du risque réel sur le "monde".
- Le but de l'apprentissage automatique est de déterminer le modèle (ou prédicteur), h qui minimise le risque empirique calculé sur le jeu de données S .

Notion de sur-apprentissage




Supposons que:

- Le jeu de données S comporte 6 points et leur couleur



(a) Distribution réelle et inconnue des données.



(b) Jeu de données d'apprentissage


Notion de sur-apprentissage




Supposons que:

- Un modèle h est disponible: une table de correspondance telle que:

$$h(x) = \begin{cases} 1, & \text{si } h(x) = 1 \\ 0 & \text{sinon} \end{cases} \quad (5)$$




(a) Distribution réelle et inconnue des données.




(b) Jeu de données d'apprentissage

Notion de sur-apprentissage



(a) Distribution réelle et inconnue des données.




(b) Jeu de données d'apprentissage

Nous pouvons calculer le risque empirique pour ce classifieur:


$$\mathcal{L}_{\text{empirical}} = 0$$

(6)

Notion de sur-apprentissage



(a) Distribution réelle et inconnue des données.



(b) Jeu de données d'apprentissage

Le risque réel que nous pouvons calculer puisque nous connaissons la distribution réelle est lui:

$$\mathcal{L}_{\text{real}} = 0.5$$

(7)



Notion de sur-apprentissage

A retenir

Le mauvais choix du classifieur nous a amené à être (beaucoup) trop confiant et nous avons:

$$\mathcal{L}_{\text{empirical}} = 0 \quad (8)$$

et

$$\mathcal{L}_{\text{real}} = 0.5 \quad (9)$$

C'est qu'on appelle du **sur-apprentissage**. Ici nous observons un cas extrême pour lequel le modèle a **appris par coeur** les données d'apprentissage. En pratique cela peut souvent arriver si notre modèle a une *trop grande* capacité de mémoire. Pensez aux modèles actuels qui ont des milliards de paramètres.

Notion de sur-apprentissage



Pourquoi le sur-apprentissage?

- Modèle trop "puissant"
- TROP peu de données

Le modèle apprend les données par coeur.

Notion de sur-apprentissage




Exemple avec l'algorithme des K plus proches voisins

Cet algorithme réduit le sur-apprentissage puisque:

$$\mathcal{L}_{\text{empirical}} = 0.0 \quad (10)$$

$$\mathcal{L}_{\text{real}} = 0.35 \quad (11)$$



Notion de sur-apprentissage




Exemple avec l'algorithme des K plus proches voisins

En ajoutant une donnée d'apprentissage, nous réduisons le risque réel:

$$\mathcal{L}_{\text{empirical}} = 0.0 \quad (12)$$

$$\mathcal{L}_{\text{real}} = 0.25 \quad (13)$$




Notion de sur-apprentissage



Comment faire tendre le risque empirique vers le risque réel

En ajoutant des données d'apprentissage, nous réduisons le risque réel.




Notion de sur-apprentissage



Est-ce réaliste?

- on souhaite mesurer des données à interval régulier
- le nombre de données pour paver l'espace augmente de façon exponentielle avec la dimension de l'espace
- L'acquisition de données d'apprentissage pour paver l'espace des données possible n'est pas réaliste



Notion de sur-apprentissage



Il faut trouver le moyen de généraliser.